

TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Ciência de Dados e Inteligência Artificial
Fase 2

Nome do estudante: Dionatan Henrique Santos de Castro


Desenvolva um processo de ciência de dados no Orange Data Mining, cobrindo os elementos abaixo.
Para cada um dos itens solicitados é necessário inserir imagens que evidenciem o trabalho realizado.


Exploração dos dados:


Que tipo de experimentos você fez na exploração dos dados (verificação de outliers, cálculos de médias, dados inválidos etc.).

Na fase de exploração, utilizei o widget **Feature Statistics** para obter estatísticas descritivas das variáveis, como média e moda, e identificar a distribuição da variável-alvo, a **UPS**. Em seguida, o **Scatter Plot** permitiu visualizar a relação entre **feridos** e **tipo_acid**, mostrando como a severidade dos acidentes varia para cada tipo.

Para complementar, a análise de **Correlations** foi utilizada para quantificar a relação linear entre a **UPS** e as outras variáveis numéricas. Essa análise mostrou que as variáveis **feridos**, **feridos_gr** e **mortes** possuem uma alta correlação positiva com a **UPS**, o que valida a importância delas para a modelagem.









Escolha de, ao menos, três algoritmos de aprendizado para a modelagem:

Apresente os algoritmos utilizados e justifique a escolha.

- Linear Regression:**
 É um modelo simples e transparente, ideal para começar e criar uma **linha de base** de desempenho. Serve para verificar se existe uma relação linear direta entre as variáveis e a severidade dos acidentes (UPS).
- Random Forest:**
 É um algoritmo robusto que lida bem com a complexidade dos dados de trânsito. Ele é capaz de capturar **padrões não lineares** e interações complexas entre variáveis, o que o torna muito eficaz para problemas como este.
- Gradient Boosting:**
 É um modelo avançado e de alto desempenho que constrói o modelo gradualmente, corrigindo os erros. É particularmente útil para identificar e prever os **casos raros de alta severidade**, que são os mais importantes para o projeto.



Random Forest - Orange

File View Window Help

Name
Random Forest

Basic Properties

Number of trees: 10

☐ Number of attributes considered at each split: 5

☐ Replicable training

☐ Balance class distribution

Growth Control

☐ Limit depth of individual trees: 3

☒ Do not split subsets smaller than: 5

☒ Apply Automatically

≡ ? | - - - -

Gradient Boosting - Orange

File View Window Help

Name
Gradient Boosting

Method
Gradient Boosting (scikit-learn)

Basic Properties

Number of trees: 100

Learning rate: 0,100

☒ Replicable training

Growth Control

Limit depth of individual trees: 3

Do not split subsets smaller than: 2

Subsampling

Fraction of training instances: 1,00

☒ Apply Automatically

≡ ? | - - - -



Preparação dos dados de acordo com as características dos algoritmos de aprendizado escolhidos:

Descreva o processo realizado para essa etapa.

Para preparar os dados para os modelos, foi realizado um processo em duas etapas:

Primeiro, as **variáveis categóricas** (tipo_acid, regioao, dia_sem) foram convertidas para um formato numérico. Isso foi feito com o widget **Continuize**, usando a técnica de *one-hot encoding*.

Em seguida, o conjunto de dados foi dividido em subconjuntos para treinamento e teste. O widget **Data Sampler** foi utilizado para separar **80% dos dados para treino** e os **20% restantes para teste**, garantindo que a avaliação dos modelos seja feita com dados que eles nunca processaram.



Execução dos experimentos de aprendizado e coleta das métricas:

Descreva o processo e os resultados obtidos.

A avaliação dos modelos foi realizada com o widget **Test & Score**. O processo utilizou **validação cruzada com 10 folds** para garantir a confiabilidade dos resultados.

As métricas de avaliação escolhidas para o problema de regressão foram o **Erro Absoluto Médio (MAE)**, a **Raiz do Erro Quadrático Médio (RMSE)**, o **Erro Quadrático Médio (MSE)** e o **Coefficiente de Determinação (R^2)**.

Modelo	MAE	RMSE	MSE	R^2
Random Forest	0.449	0.638	0.407	0.820
Gradient Boosting	0.457	0.647	0.418	0.815
Linear Regression	0.485	0.686	0.471	0.793

O Random Forest foi melhor, pois obteve o melhor desempenho, com o menor erro (RMSE de **0.638**) e a maior capacidade de explicação dos dados (R^2 de **0.820**).

The screenshot shows the 'Test and Score' widget in the Orange Data Mining software. The left sidebar contains configuration options for cross-validation, random sampling, and data testing. The main area displays a table of performance metrics for three models: Linear Regression, Random Forest, and Gradient Boosting. Below this, a comparison table shows the probabilities of one model outperforming another based on the Mean Square Error (MSE) metric.

Widget Configuration:

- Cross validation:** Number of folds: 5, Stratified (checked).
- Random sampling:** Repeat train/test: 10, Training set size: 66%, Stratified (checked).
- Test on:** Test on test data.

Performance Metrics Table:

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	1.233	1.110	0.642	28.959	0.725
Random Forest	0.429	0.655	0.062	2.308	0.904
Gradient Boosting	0.373	0.610	0.070	2.620	0.917

Model Comparison Table (Mean square error):

	Linear Regression	Random Forest	Gradient Boosting
Linear Regression	-	0.999	1.000
Random Forest	0.001	-	0.911
Gradient Boosting	0.000	0.089	-

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Status: Stratification is ignored for regression

Relato dos experimentos e lições aprendidas:

Apresente uma reflexão acerca dos resultados obtidos com este projeto.

A execução deste projeto permitiu uma reflexão aprofundada sobre a aplicação prática de algoritmos de aprendizado de máquina para prever a severidade de acidentes de trânsito em Porto Alegre.

A principal conclusão é que a modelagem preditiva para um problema como este exige modelos capazes de capturar complexas relações não lineares. Os resultados obtidos validam essa premissa:

- **Superioridade de modelos mais complexos:** O **Random Forest** obteve o melhor desempenho com um **R^2 de 0.820** e **RMSE de 0.638**. Ele superou o **Gradient Boosting** (R^2 de 0.815 e RMSE de 0.647) e, especialmente, a **Regressão Linear** (R^2 de 0.793), que teve o pior resultado. A superioridade do Random Forest reside na sua capacidade de **construir múltiplas árvores de decisão e combinar seus resultados**, o que lhe permite capturar interações complexas entre variáveis de forma mais eficaz do que o Gradient Boosting e o modelo linear. Isso sugere que a relação entre a severidade dos acidentes e as variáveis do conjunto de dados não é simples ou linear.
- **Importância da variável-alvo:** A escolha da UPS como variável-alvo se mostrou crucial. Por ser uma escala contínua, ela permitiu que os modelos de regressão capturassem uma gama completa de severidades, desde acidentes leves até os mais graves, algo que uma variável binária (como mortes) não faria. A análise inicial mostrou que a maioria dos acidentes tem baixa severidade, um desequilíbrio que, em projetos futuros, poderia ser tratado com técnicas de reamostragem para melhorar a previsão dos casos mais raros e críticos.

Em suma, o projeto demonstra o potencial da ciência de dados para transformar dados brutos de acidentes em inteligência aplicada à segurança viária. As descobertas aqui podem servir como base para aprimorar políticas públicas, identificar pontos de risco e orientar a alocação de recursos de forma mais eficaz, focando na prevenção de acidentes de maior gravidade.

Link para o arquivo do projeto do Orange e dos dados utilizados:

Insira os links para os arquivos.

Dataset:

[Acidentes de Trânsito - Acidentes - Conjuntos de dados - Dados Abertos - POA](#)

Projeto no Orange:

[fluxograma fase 2.ows](#)